Textos humanos ou gerados por IA?

Reconstrução experimental com Word2Vec + BiLSTM

Alexandre Lampert · Felipe Lucca · Gabriel Silva

Gustavo Pigatto · Leonardo Forgiarini · João Vitor Frare

Ciência da Computação | UNOESC — Disciplina: Inteligência Artificial
Professor: Vinícius Almeida dos Santos

O artigo que orienta o experimento

Classifying human vs. AI text with machine learning and explainable transformer models

Adven Masih · Bushra Afzal · Shamyla Firdoos · Jabar Mahmood
Aitizaz Ali · Mohamed Shabbir Abdulnabi · Daniel Musafiri Balungu

PUBLICAÇÃO

Scientific Reports

Volume 15 · Artigo 43310 · 2025
DOI: 10.1038/s41598-025-27377-z

RECORTE ESCOLHIDO

Word2Vec + BiLSTM

Dimensão 200 · Semente 123
Experimento recorrente da Tabela 6

JOÃO VITOR FRARE

O problema e o objetivo

PROBLEMA

Textos semelhantes

A escrita gerada por IA pode se aproximar da escrita humana e dificultar a distinção.

TAREFA

Duas classes

Receber um texto e prever um dos rótulos: humano (0) ou IA (1).

OBJETIVO

Reproduzir e avaliar

Treinar uma rede do artigo, medir seus erros e discutir diferenças nos resultados.

A classificação estima padrões da base; não comprova a autoria de um texto.

Masih et al. (2025) · DOI: 10.1038/s41598-025-27377-z

Da metodologia original ao nosso recorte

No artigo

Dados rotulados → processamento → modelos neurais → treinamento → teste e comparação.

Neste trabalho

Base original → Word2Vec → BiLSTM → comparação com a linha correspondente da Tabela 6.

Reconstrução parcial, com escolhas explícitas

Os autores não disponibilizaram o código recorrente completo. As lacunas estão documentadas em METODOLOGIA.md.

Os dados são os mesmos do repositório

20.000

textos em inglês · 50% humano / 50% IA



Divisões estratificadas · Semente 123 · Índices e hashes registrados

LEONARDO FORGIARINI

Preparação: do texto aos vetores

01

Limpeza

Minúsculas, pontuação e stopwords inglesas.

02

Tokens

Separação por espaços; limite de 200 tokens.

03

Word2Vec

Vetores de 200 dimensões, aprendidos só no treino.

Vocabulário: 27.133 entradas. incluindo PAD e UNK

Word2Vec skip-gram: 5 épocas, janela 5; configurações locais documentadas.

Masih et al. (2025) · DOI: 10.1038/s41598-025-27377-z

A arquitetura neural implementada

Entrada
até 200 tokens

→

Embedding
200 dimensões

→

BiLSTM
64 + 64 unidades

→

Linear
128 → 2 logits

→

Softmax
Humano / IA

Memória em duas direções

A rede percorre a sequência da esquerda para a direita e no sentido inverso.

5.563.050 parâmetros treináveis · Portas sigmoid · Estado tanh

64 unidades por direção e uma camada: escolhas de reconstrução, não dados publicados.

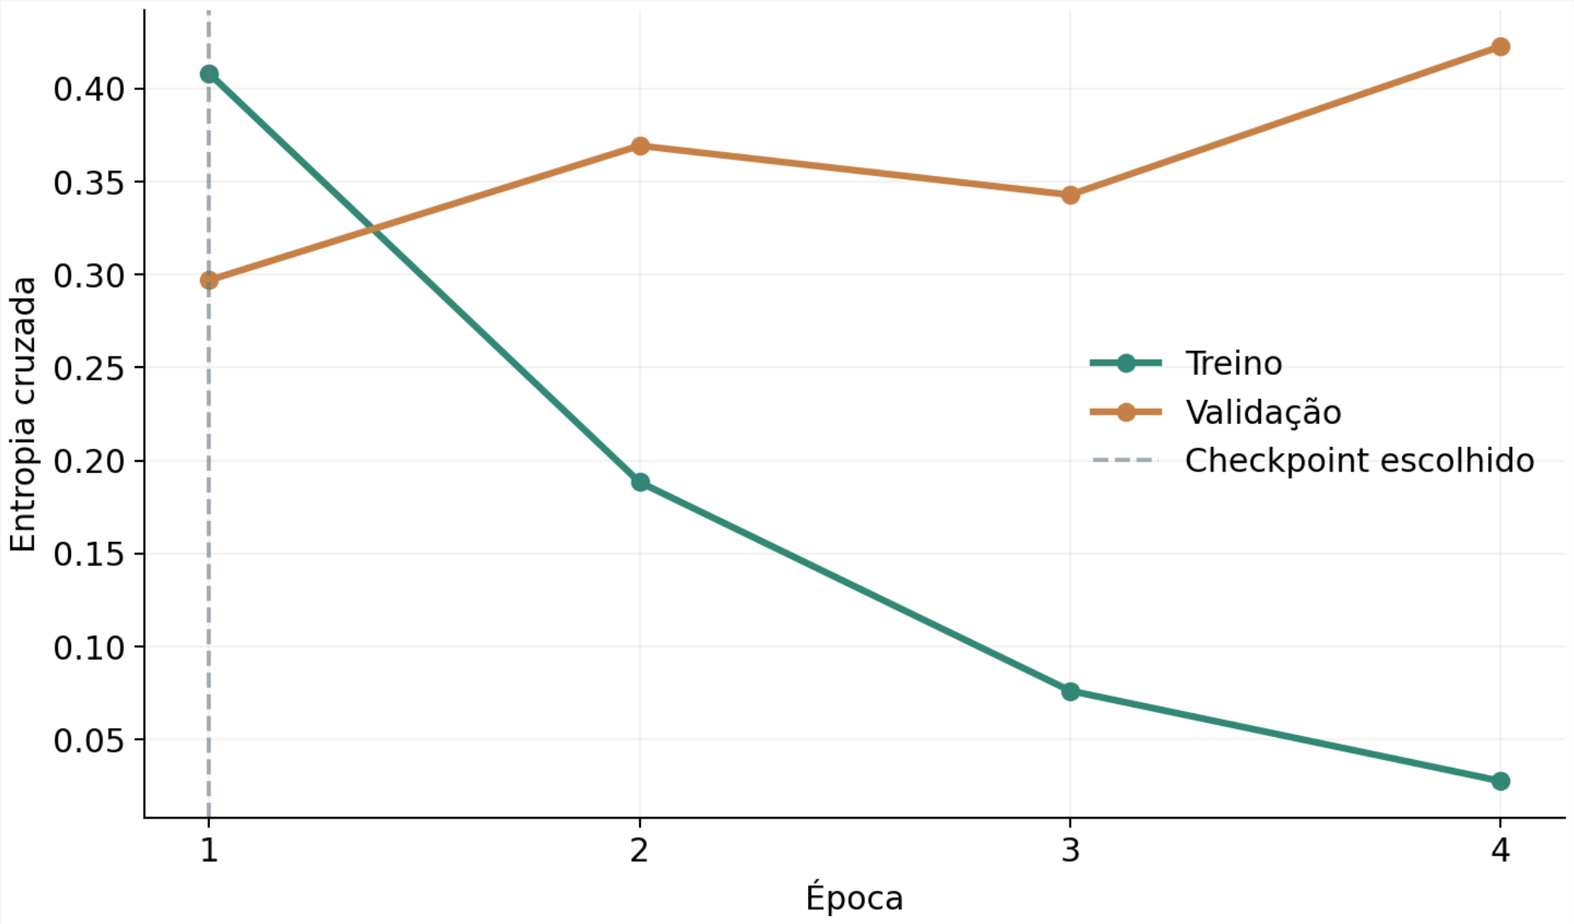
GABRIEL SILVA

Como o modelo aprendeu

Adam · 0,001

Lote 32
CrossEntropyLoss
Até 30 épocas
Paciência: 3

4 épocas executadas
Checkpoint: época 1
Tempo: 4.9 min em CPU



Parâmetros: Tabela 4 do artigo · Curvas: resultados/seed123/historico.json

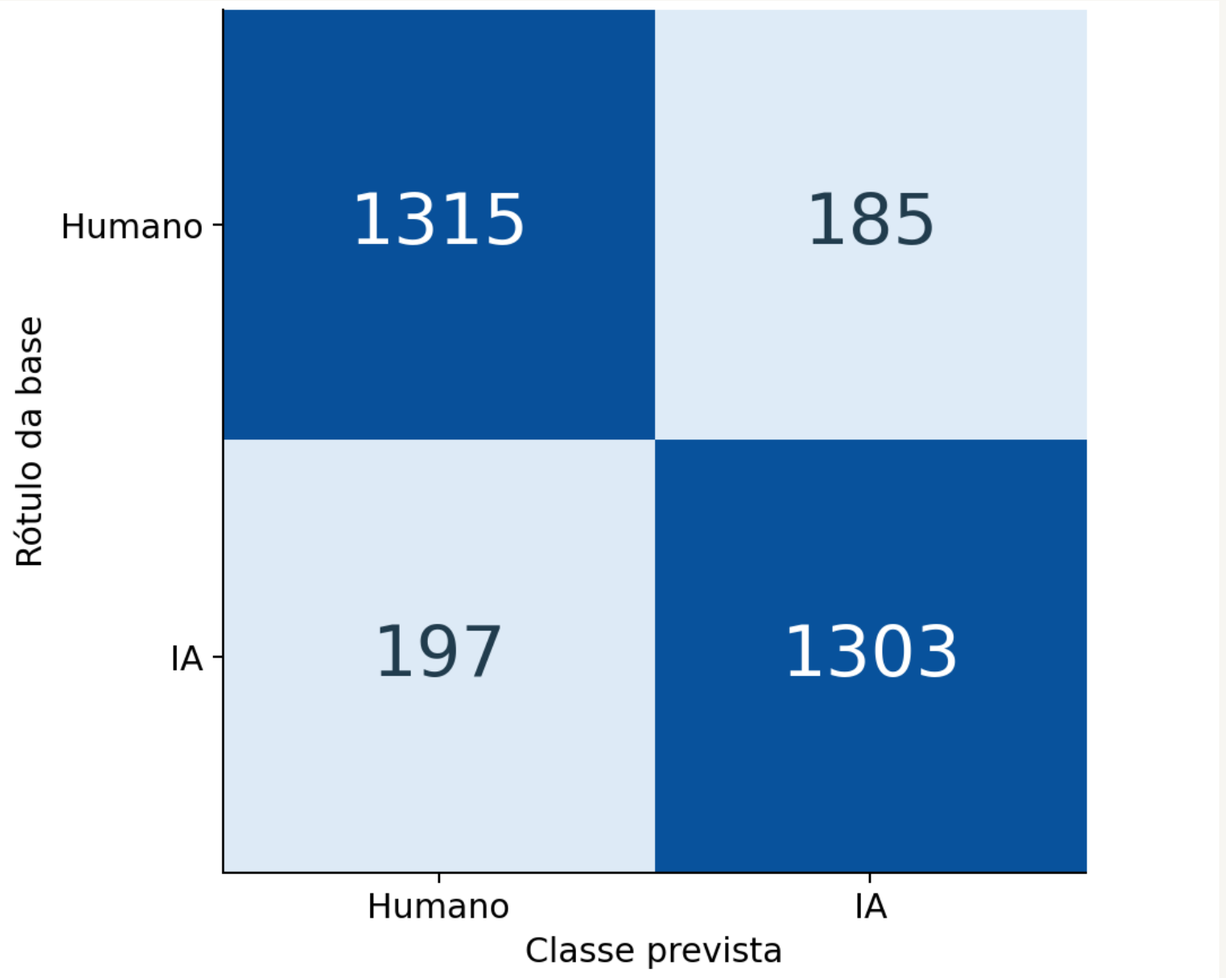
Resultado real nos 3.000 textos de teste

87.27%

Acurácia

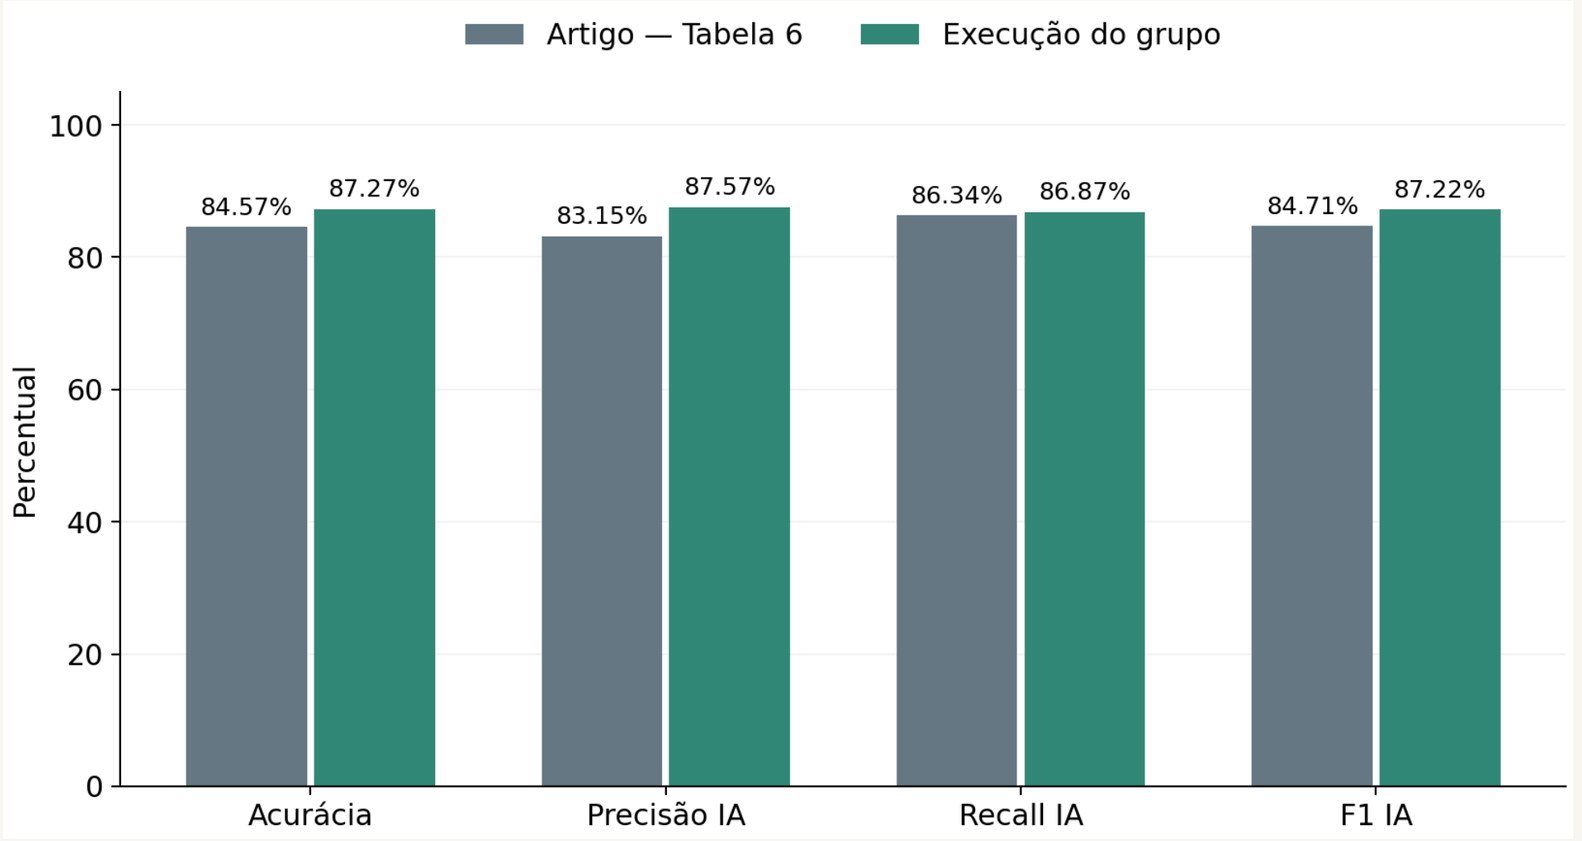
Precisão IA 87.57%
Recall IA 86.87%
F1 IA 87.22%

185 humanos apontados como IA
197 textos de IA apontados como humanos



Fonte: resultados/seed123/relatorio.json e predicoes_teste.csv · Execução local

Artigo × execução do grupo



Diferença observada de acurácia: +2.70 pontos percentuais.

Comparação descritiva: pesos, arquitetura detalhada e divisão original não são idênticos ou verificáveis.

Auditoria: o que limita a comparação

DADOS

185 repetições

Linhas excedentes após limpeza; 36 grupos de textos com rótulos conflitantes.

TESTE COMPLEMENTAR

32 linhas excluídas

2.968 textos sem hashes vistos. Acurácia: 87.33%.

GENERALIZAÇÃO

Uma configuração

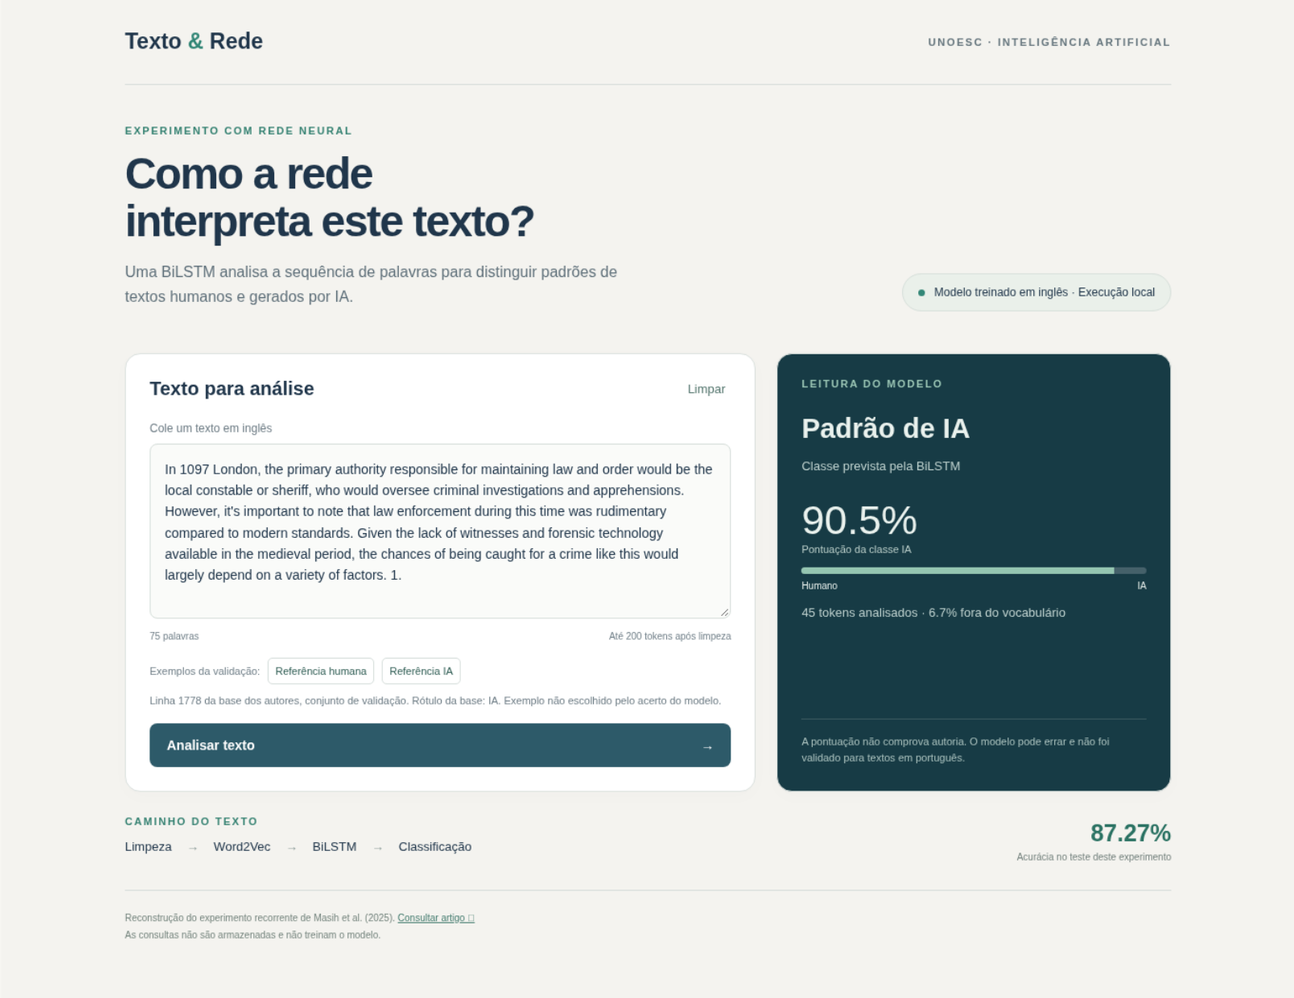
Inglês, uma semente e uma base. Não demonstra desempenho geral ou certeza de autoria.

Possíveis causas das diferenças: embeddings, unidades da LSTM, limpeza, divisão e inicialização.

A avaliação complementar não substitui um teste externo independente.

Fonte: resultados/seed123/auditoria.json e relatorio.json

Demonstração da rede em funcionamento



1. Inserir

Texto em inglês ou exemplo da validação.

2. Analisar

Limpeza → vetores → BiLSTM → pontuação.

3. Interpretar

A previsão pode errar; score não é prova de autoria.

Captura real da interface local · Modelo carregado: resultados/seed123/modelo.pt

Dificuldades e decisões de implementação

Código recorrente não disponibilizado

Reconstruímos a BiLSTM e registramos as decisões que não aparecem no artigo.

Recursos de execução

Treinamento em CPU. Downloads dos pesos de transformers bloqueados no ambiente.

Sobreajuste e qualidade da base

A validação evitou usar o último checkpoint; a auditoria revelou repetições e conflitos.

Próximos passos: outras sementes, teste externo e confirmação dos detalhes com os autores.

O que conseguimos reproduzir

Uma rede treinada.
Resultados verificáveis.

Base original · BiLSTM · Treino e teste · Interface · Comparação

A reconstrução permitiu estudar aprendizado, sobreajuste e erros de classificação. As lacunas da fonte impedem afirmar reprodução exata.

Fontes: artigo de Masih et al. (2025), repositório dos autores e relatórios desta execução.
Código, pesos, divisões, previsões e apresentação acompanham a entrega.